

Министерство науки и высшего образования Российской Федерации Федеральное государственное бюджетное образовательное учреждение высшего образования

«Московский государственный технический университет имени Н.Э. Баумана (напиональный исследовательский университет)»

(национальный исследовательский университет)» (МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ	«Информатика и системы управления (ИУ)»
КАФЕДРА	«Программное обеспечение ЭВМ и информационные технологии (ИУ7)»

ТЕХНИЧЕСКОЕ ЗАДАНИЕ *К КУРСОВОМУ ПРОЕКТУ НА ТЕМУ:*

«Разработка компилятора языка tinyc»

Студент группы ИУ7-21М		В.А. Иванов
	(Подпись, дата)	(И.О. Фамилия)
Руководитель		А.А. Ступников
	(Подпись, дата)	(И.О. Фамилия)

Министерство науки и высшего образования Российской Федерации Федеральное государственное бюджетное образовательное учреждение высшего образования

«Московский государственный технический университет имени Н.Э. Баумана (национальный исследовательский университет)» (МГТУ им. Н.Э. Баумана)

	УТ	ВЕРЖДАЮ
		кафедрой <u>ИУ7</u>
	, ,	(Индекс)
		<u>И.В.Рудаков</u>
		(И.О.Фамилия)
	«	» 20 г.
ЗАДА	НИЕ	
на выполнение к	урсового проекта	a
по дисциплине Конструирование комп	иляторов	
Студент группы ИУ7-21М		
·	лод Алексеевич	
(Фамилия, и	мя, отчество)	
Тема курсового проекта Разработка компилятора языка	tinyc	
Направленность КП (учебный, исследовательский, прак		
<u>учебный</u> Источник тематики (кафедра, предприятие, НИР)		
Источник тематики (кафедра, предприятие, НИР)	Кафедра	·
График выполнения проекта: 25% к $\underline{4}$ нед., 50% к $\underline{7}$ не	ед., 75% к <u>11</u> нед., 100% к <u>1</u> 4	<u>1</u> нед.
Задание Описать грамматику языка tinyc, расширить с языка Си. Разработать компилятор расширенного яз использовать утилиту ANTLR4 для преобразования соответствии с описанной грамматикой. В качестве генерации промежуточного представления на основе соответство представления пре	ыка tinyc. В качестве фр исходного кода в синта бекенда компилятора испо	онтенда компилятора аксическое дерево в ользовать LLVM для
Оформление курсового проекта:		
Расчетно-пояснительная записка на 20-30 листах форматрасчетно-пояснительная записка должна содержать конструкторскую, технологическую части, заключение и	постановку задачи, введ	дение, аналитическую,
Дата выдачи задания « 2 » <u>марта</u> 2023 г.		
Руководитель курсового проекта		А.А.Ступников
v v v i	(Подпись, дата)	(И.О.Фамилия)
Студент		В.А.Иванов
	(Подпись, дата)	(И.О.Фамилия)

СОДЕРЖАНИЕ

BI	ВВЕДЕНИЕ		
1	Ана	алитическая часть	5
	1.1	Составляющие компилятора	5
		1.1.1 Препроцессор	5
		1.1.2 Лексический анализатор	6
		1.1.3 Синтаксический анализатор	6
		1.1.4 Семантический анализ	6
		1.1.5 Генерация кода	7
	1.2	ANTLR4	7
	1.3	LLVM	8
2	Кон	иструкторская часть	9
	2.1	IDEF0	9
	2.2	Грамматика языка tinyc	9
	2.3	Обход синтаксического дерева	10
	2.4	Генерация LLVM IR	12
	СПІ	ИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	14
П	ри па	ОЖЕНИЕ А	15

ВВЕДЕНИЕ

Компилятор — программа, переводящая написанный на языке программирования текст в набор машинных кодов[1].

Целью данного курсового проекта является разработка компилятора для языка программирования tinyc. В данной курсовой работе грамматика данного языка будет расширена за счёт элементов грамматики языка Си. Это делается для удволетворения требований к курсовому проекту по наличию более сложных элементов языка, чем имеющиеся в данной грамматике.

Основные задачи, которые необходимо выполнить в рамках данного проекта:

- 1) Провести анализ существующей грамматики языка tinyc, и расширить ее поддержкой массивов, используя грамматику языка Си.
- 2) Разработать лексический и ситнтаксический анализатор с использованием утилиты ANTLR4.
- 3) Разработать семантический анализатор для генерации промежуточного представления LLVM.
- 4) Провести тестирование компилятора.

1 Аналитическая часть

1.1 Составляющие компилятора

Компилятор состоит из следующих составляющих подпрограмм:

- Frontend компилятора отвечает за первичную обработку исходного кода и создание внутреннего представления программы. Он состоит из следующих частей:
 - препроцессор;
 - лексический анализатор;
 - синтаксический анализатор;
 - семантический анализатор;
 - генератор промежуточного представления;
- Middle-end компилятора занимается оптимизацией и преобразованием промежуточного представления программы.
- Васkend компилятора отвечает за генерацию целевого кода, который может быть выполнен на конкретной аппаратной платформе или виртуальной машине.

В данной работе функции Middle-end и Backend компилятора будут осуществляться библиотекой LLVM, поэтому рассмотрим более подробно Frontend составляющих компилятора.

1.1.1 Препроцессор

Препроцессор компилятора - это компонент компилятора, который выполняет предварительную обработку исходного кода перед фазой фронтенда. Его задача заключается в обработке директив препроцессора и внесении соответствующих изменений в исходный код.

Препроцессор предоставляет набор директив, которые позволяют включать или исключать определенные части исходного кода, задавать макросы для замены текста и включать заголовочные файлы. Примером директив языка Си являются include, define, pragma. После работы препроцессора изменённый

исходный код программы подаётся на вход лексический анализатора.

В данном проекте препроцессор не используется ввиду его избыточности.

1.1.2 Лексический анализатор

Лексический анализатор выполняет первичную обработку исходного кода, разбивая его на лексемы. Лексема - минимальный элемент исходного кода. Примеры: ключевые слова, идентификаторы, операторы, константы и символы пунктуации.

Задачи лексического анализатора:

- разбиение исходного кода на лексемы;
- идентификация типов лексем;
- удаление незначащих символов;
- формирование потока токенов для синтаксического анализатора;

1.1.3 Синтаксический анализатор

Синтаксический анализатор выполняет построение синтаксического дерева из полученного потока токенов, которое представляет иерархическую структуру программы. Обычно это представление выражается в виде абстрактного синтаксического дерева (АСТ), где каждый внутренний узел является оператором, а дочерние его аргументами.

Задачи синтаксического анализатора:

- проверка синтаксической корректности (соответствие грамматике);
- построение синтаксического дерева;
- обработка ошибок.

Полученное представление программы в виде синтаксического дерева используется на следующем этапе.

1.1.4 Семантический анализ

Семантический анализатор выполняет проверку семантики исходного кода, включая правильное использование типов данных, правила области видимости и согласованность операций.

Задачи семантического анализатора:

- установить семантическую связь между различными частями программы;
- выявить потенциальные ошибки и несоответствия типов.

Семантический анализатор составляет таблицу символов, описывающую хранящиеся типы данных.

1.1.5 Генерация кода

Генерация кода - это фаза компиляции, в которой основываясь на синтаксическом дереве программы и системных таблиц создаётся её код.

Получение машинного кода осуществляется в два этапа.

- 1) Генерация промежуточного кода относится к последней фазе frontend компилятора.
- 2) Генерация машинного кода относится к middle-end и backend компилятора.

Основные этапы генерации кода включают:

- оптимизация промежуточного представления;
- выбор инструкций целевой платформы, соотвествующие промежуточному представлению;
- связывание данных с именами переменных;
- собственно генерация кода.

Результатом этого этапа является исполняемый на целевой платформе код.

1.2 ANTLR4

В качестве лексического и синтаксического анализатора будет использован ANTLR4 (ANother Tool for Language Recognition). Выбор обосновывается рядом преимуществ и особенностей данного инструмента:

- поддержка генерацию лексических и синтаксических анализаторов для широкого спектра языков программирования;
- удобный и интуитивно понятный синтаксис для описания грамматик языков программирования;
- автоматическая генерация синтаксического дерева;

• широкая и активная пользовательская база и развитое сообщество разработчиков.

1.3 LLVM

В качестве генератора кода используется LLVM (Low Level Virtual Machine). Его выбор обосновывается следующими факторами:

- Поддержка большого количества целевых платформ.
- Поддержка библиотек на различных языках (C, C++, Rust, Python и другие).
- Поддержка основных типы данных: целые числа, числа с плавающей точки различных точностей, массивы, структуры, функции.
- Автоматическая оптимизация сгенерированного промежуточного представления.
- Широкая и активная пользовательская база и развитое сообщество разработчиков.
- Имеется интерпретатор промежуточного представления.

Выводы

В данном разделе был проведён обзор основных фаз компиляции. Обоснованы выборы средств лексического и синтаксического анализа - ANTLR4 и генератора машинного кода - LLVM. Метод работы компилятора будет заключаться в генерации синтаксического дерева и генерации по нему промежуточного представления кода (LLVM IR).

2 Конструкторская часть

2.1 IDEF0

Концептуальная модель программы представлена в нотации IDEF0 на рисунке 2.1

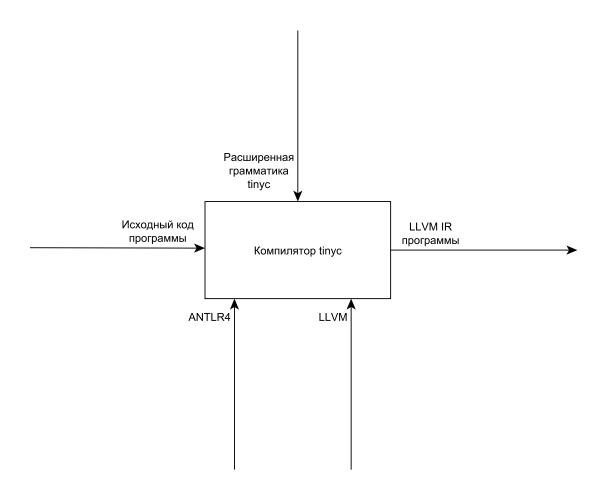


Рисунок 2.1 – Концептуальная модуль системы в нотации IDEF0.

2.2 Грамматика языка tinyc

Грамматика языка tinyc 3 является крайне упрощённым вариантом грамматики языка Си.

Листинг 1: Грамматика языка tinyc

```
grammar tinyc;
program: statement + EOF;
statement
: 'if' paren_expr statement
```

```
| 'if' paren_expr statement 'else' statement
6 | 'while' paren expr statement
7 | 'do' statement 'while' paren expr ';'
   | '{' statement* '}'
    | expr ';'
    1 7, 1
12 paren expr: '(' expr ')';
13 expr: test | id_ '=' expr;
14 test: sum | sum '<' sum ;
15 sum_: term | sum_ '+' term | sum_ '-' term;
16 term: id_ | integer | paren_expr;
18 id : STRING;
19 integer: INT;
20 STRING: [a-z]+;
21 INT: [0-9]+;
22 WS: [ \r\n\t] -> skip;
```

Так как эта грамматика не удовлетворяла требованиям курсовой работы, она была дополнена элементами грамматики Си. Были добавлены следующие элементы синтаксиса:

- недостающие арифметические операции с учётом приоритетов действий;
- объявления и инициализация переменных;
- поддержка многомерных статических массивов;
- комментарии.

Полная дополненная грамматика приведена в Приложении А.

2.3 Обход синтаксического дерева

Исходная программа преобразовывается в синтаксическое дерево при помощи кода, сгенерированного ANTLR4 для описанной грамматики. Обход всех узлов данного представления позволяет сгенерировать LLVM IR.

Рассмотрим синтаксическое дерево на примере изображения 2.2.

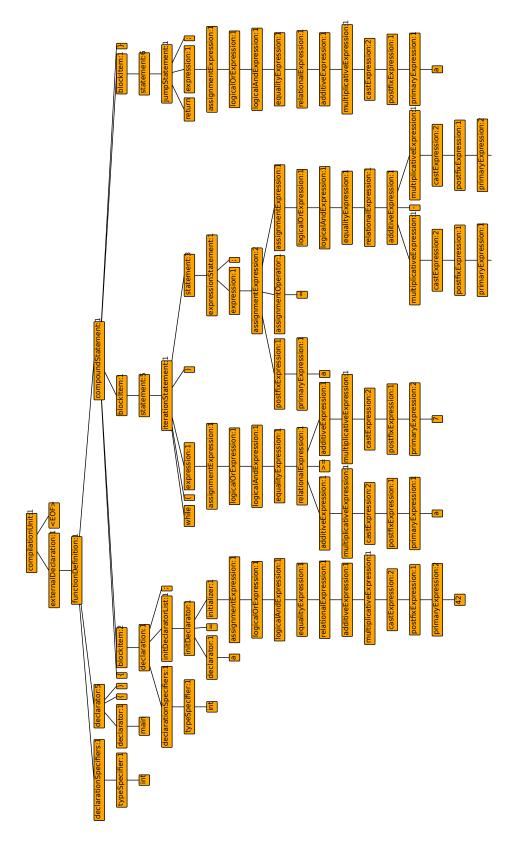


Рисунок 2.2 – Пример визуализации синтаксического дерева.

Данная визуализация получена использованием утилиты **antlr4-parse** для следующей программы, вычисляющей остаток от деления числа на 7.

Листинг 2: Пример программы (остаток от деления на 7)

```
int main() {
   int a = 42;
   while(a >= 7)
   a = a - 7;
   return a;
}
```

2.4 Генерация LLVM IR

Сгенерировать промежуточное представление LLVM можно путём обхода всех узлов синтаксического дерева. Каждый узел может создавать новые инструкции, блоки, функции и т.п. в зависимости от его типа и дочерних узлов. Рассмотрим пример обработки узла **iterationStatement**, грамматика которого показана в выражении 1. На рисунке 2.3 приведена схема алгоритма генерации кода для цикла while.

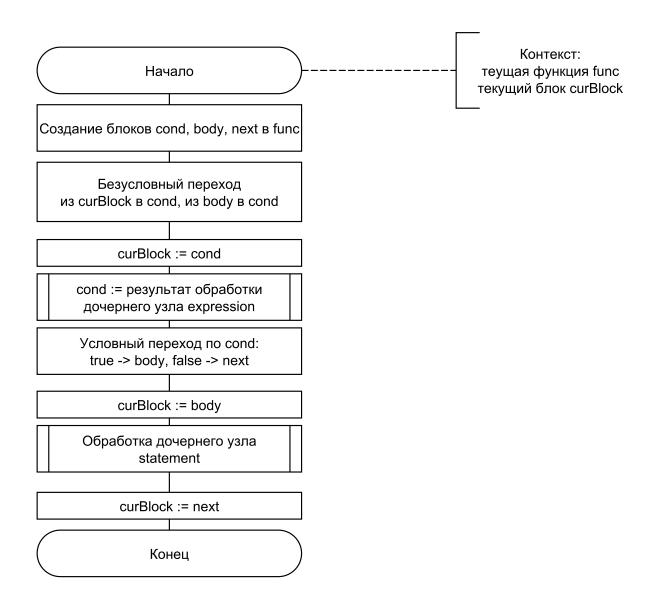


Рисунок 2.3 – Схема алгоритма обработки узла iterationStatement.

Вывод

В данном разделе была предоставлена концептуальная модель метода компиляции в нотации диаграммы IDEF0. Приведена грамматика tinyc, описаны предпринятые расширения. Описаны работы frontend часть разрабатываемого компилятора.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. ГОСТ 19781-83 // Вычислительная техника. Терминология: Справочное пособие. Выпуск 1 / Рецензент канд. техн. наук Ю. П. Селиванов. — М.: Издательство стандартов, 1989. - 168 с. — $55\,000$ экз. — ISBN 5-7050-0155-X.;

ПРИЛОЖЕНИЕ А

Листинг 3: Дополненная грамматика языка tinyc

```
1 grammar tinyc;
 2 primaryExpression
     : Identifier
     Constant
     | StringLiteral+
          '(' expression ')'
9 genericAssocList
10 : genericAssociation (',' genericAssociation)*
11
12
13 genericAssociation
14 : typeName ':' assignmentExpression
15
17 postfixExpression
18
      ( primary Expression
20
      '(' typeName ')' '{' initializerList ','? '}'
21
     ('[' expression ']'
    '(' argumentExpressionList? ')'
24
25
26
27 argumentExpressionList
28
   : assignmentExpression (',' assignmentExpression)*
29
31 \quad unary Expression: \ unary Operator \ cast Expression;
32
33 unaryOperator: '+' | '-' | '!';
35 castExpression
     : '(' typeName ')' castExpression
    postfixExpression
37
    unaryExpression
39
40
41 multiplicativeExpression
42
   : castExpression (('*'|'/'|'%') castExpression)*
43
44
45 additiveExpression
46 : multiplicativeExpression (('+'|'-') multiplicativeExpression)*
47
48
49 relationalExpression
50
   : additiveExpression (('<'|'>'|'<='|'>=') additiveExpression)*
51
53 equalityExpression
54 : relationalExpression (('=='| '!=') relationalExpression)*
55
57 logicalAndExpression
58 : equalityExpression ('&&' equalityExpression)*
59
61 logicalOrExpression
62 : logicalAndExpression ( '|| ' logicalAndExpression)*
```

```
63
64
65 assignmentExpression
66 : logicalOrExpression
   postfixExpression assignmentOperator assignmentExpression
67
69
70 assignmentOperator: '=';
71
72 expression
73 : assignmentExpression (',' assignmentExpression)*
74
76 declaration
?? : declarationSpecifiers initDeclaratorList? ';'
78
79
80 declarationSpecifiers
81 : typeSpecifier+
82
84 initDeclaratorList
85 : initDeclarator (',' initDeclarator)*
86
87
88 initDeclarator
89 : declarator ('=' initializer)?
91
92 typeSpecifier
93 : 'char'
94 | 'int'
95 | 'float'
96
98 specifierQualifierList
99 : typeSpecifier specifierQualifierList?
100
101
102 structDeclaratorList
: structDeclarator (',' structDeclarator)*
104
106 structDeclarator
107 : declarator
     | declarator? ':' logicalOrExpression
108
109
110
111 declarator
112 : Identifier
113
    | '(' declarator ')'
     declarator '[' assignmentExpression? ']'
114
     declarator '(' parameterTypeList ')'
115
116
      | declarator '(' identifierList? ')'
117
118
119
120 gccAttribute
     . . , ' ' ' ' ' ' relaxed def 1
('(' argumentExpressionList? ')')?
;
121 : \sim (',' \mid '(' \mid ')') // relaxed def for "identifier or reserved word"
122
123
124
125 nestedParenthesesBlock
126 : ( ~('(' | ')')
     '(' nestedParenthesesBlock ')'
128
         )*
129
130
131
```

```
132 parameterTypeList
133 : parameterList (',' '...')?
134
135
136 parameterList
: parameterDeclaration (',' parameterDeclaration)*
138
139
140 parameterDeclaration
141 : declarationSpecifiers (declarator | abstractDeclarator?)
142
143
144 identifierList
145 : Identifier (',' Identifier)*
146
147
148 typeName
149 : specifierQualifierList abstractDeclarator?
150 ;
151
152 abstractDeclarator
153 : '(' abstractDeclarator ')'
     | '[' assignmentExpression? ']'
154
    | '[' '*' ']'
| '(' parameterTypeList? ')'
| abstractDeclarator '[' assignmentExpression? ']'
155
156
157
    abstractDeclarator '[' '*' ']'
158
    abstractDeclarator '(' parameterTypeList? ')'
160
161
162 initializer
163 : assignmentExpression
164 | '{' initializerList ','? '}'
    ;
165
167 initializerList
: designation? initializer (',' designation? initializer)*
169
170
171 designation
172 : designatorList '='
173
174
175 designatorList
176 : designator+
177
     ;
178
179 designator
: '[' logicalOrExpression ']'
181 | '.' Identifier
182 ;
183
184 statement
   : labeledStatement
185
      compoundStatement
186
    expressionStatement
187
    selectionStatement
189 | iterationStatement
190
    | jumpStatement
191
      ;
192
193 labeledStatement
194 : Identifier ':' statement
195
197 compoundStatement
   : '{' blockItem* '}'
198
199
200
```

```
201 blockItem
202 : statement
    declaration;
203
204
205
206 expressionStatement
207 : expression? ';'
208
209
210 selectionStatement
211 : 'if' '(' expression ')' statement ('else' statement)?
212
213
214 iterationStatement
215 : While '(' expression ')' statement
216
217
218 jumpStatement: 'return' expression ';';
219
220 compilationUnit
221 : externalDeclaration+ EOF
222 ;
223
224 externalDeclaration
225 : function Definition
226 | declaration
227 | ';'
228
229
230 functionDefinition
231 : declarationSpecifiers? declarator declarationList? compoundStatement
232
233
234 declarationList
235 : declaration+
236
237
238 Auto : 'auto';
239 Break : 'break';
240 Char : 'char';
241 Const : 'const';
242 Continue : 'continue';
243 Else : 'else';
244 Extern : 'extern';
245 Float : 'float';
246 Goto : 'goto';
247 If : 'if';
248 Inline : 'inline';
249 Int : 'int';
250 Register : 'register';
251 Restrict : 'restrict';
252 Return : 'return';
253 Sizeof : 'sizeof';
254 Struct : 'struct';
255 Switch : 'switch';
256 Typedef : 'typedef';
257 Union : 'union';
258 While : 'while';
259
260 Noreturn : '_Noreturn';
261
262 LeftParen : '(';
263 RightParen : ')';
264 LeftBracket : '[';
265 RightBracket : ']';
266 LeftBrace : '{';
267 RightBrace : '}';
268
269 Less : '<';
```

```
270 LessEqual : '<=';
271 Greater : '>';
272 GreaterEqual : '>=';
273 LeftShift : '<<';
274 RightShift : '>>';
275
276 Plus : '+';
277 Plus Plus : '++';
278 Minus : '-';
279 MinusMinus : '--';
280 Star : '*';
281 Div : '/';
282 Mod : '%';
283
284 And : '&';
285 Or : '|';
286 AndAnd : '&&';
287 OrOr : '||';
288 Caret : '^';
289 Not : '!';
290 Tilde : '~';
291
292 Question : '?';
293 Colon : ':';
294 Semi : ';';
295 Comma : ',';
296
297 Assign : '=';
298
299 Equal : '==';
300 NotEqual : '!=';
301
302 Arrow : '->';
303 Dot : '.';
304 Ellipsis : '...';
305
306 Identifier
    : IdentifierNondigit
307
        ( IdentifierNondigit
308
309
           | Digit
         )*
310
311
312
313 fragment
314 IdentifierNondigit
315 : Nondigit
    | UniversalCharacterName;
316
317
318
319 fragment
320 Nondigit
321 : [a-zA-Z_]
322
323
324 fragment
325 Digit
326 : [0-9]
327 ;
328
329 fragment
330 UniversalCharacterName
331 : '\\u' HexQuad
332 | '\\U' HexQuad HexQuad
333
334
335 fragment
336 HexQuad
337 : HexadecimalDigit HexadecimalDigit HexadecimalDigit HexadecimalDigit 338 ;
```

```
339
340 Constant

    341 : IntegerConstant
    342 | FloatingConstant
    343 | CharacterConstant

344
345
346 fragment
347 IntegerConstant
    : DecimalConstant
| OctalConstant
348
349
     HexadecimalConstant
350
    BinaryConstant
351
352
353
354 fragment
355 BinaryConstant
356 : '0' [bB] [0-1]+
357 ;
358
359 fragment
360 DecimalConstant
361 : NonzeroDigit Digit*
362
363
364 fragment
365 OctalConstant
366 : '0' OctalDigit*
367 ;
368
369 fragment
370 HexadecimalConstant
371 : HexadecimalPrefix HexadecimalDigit+
372
373
374 fragment
375 HexadecimalPrefix
376 : '0' [xX]
377
378
379 fragment
380 NonzeroDigit
381 : [1-9]
382 ;
383
384 fragment
385 OctalDigit
386 : [0-7]
387
388
389 fragment
390 HexadecimalDigit
391 \qquad : \qquad [\,0\,{-}9\,a{-}fA{-}F\,]
392
393
394 fragment
395 FloatingConstant
396 : DecimalFloatingConstant
397
    | HexadecimalFloatingConstant
398
399
400 fragment
401 DecimalFloatingConstant
402 : FractionalConstant ExponentPart? FloatingSuffix?
403
    | DigitSequence ExponentPart FloatingSuffix?
404 ;
405
406 fragment
407 HexadecimalFloatingConstant
```

```
: HexadecimalPrefix (HexadecimalFractionalConstant | HexadecimalDigitSequence) BinaryExponentPart FloatingSuffix?
408
409
410
411 fragment
412 FractionalConstant
413 : DigitSequence? '.' DigitSequence
414
   | DigitSequence '.'
415
416
417 fragment
418 ExponentPart
419 : [eE] Sign? DigitSequence
420
421
422 fragment
423 Sign
424 : [+-]
425 ;
426
427 DigitSequence
428 : Digit+
429
430
431 fragment
432 HexadecimalFractionalConstant
: HexadecimalDigitSequence? '.' HexadecimalDigitSequence
434
    | HexadecimalDigitSequence '.'
435
436
437 fragment
438 BinaryExponentPart
439 : [pP] Sign? DigitSequence
440
441
442 fragment
443 HexadecimalDigitSequence
444 : HexadecimalDigit+
445
446
447 fragment
448 Floating Suffix
449 : [flFL]
450
451
452 fragment
453 CharacterConstant
454 : '\'' CCharSequence '\''
      L\'' CCharSequence '\''
455
    | 'u\'' CCharSequence '\''
456
457
    U\'' CCharSequence '\''
458
459
460 fragment
461 CCharSequence
462 : CChar+
463
464
465 fragment
466 CChar
467 : ~['\\r\n]
    | EscapeSequence ;
468
469
470
471 fragment
472 EscapeSequence
473 : SimpleEscapeSequence
474
     | OctalEscapeSequence
    | HexadecimalEscapeSequence
| UniversalCharacterName
475
476
```

```
477 ;
478
479 fragment
480 SimpleEscapeSequence
481 : '\\' ['"?abfnrtv\\]
482 ;
483
484 fragment
485 OctalEscapeSequence
486 : '\\' OctalDigit OctalDigit? OctalDigit?
487
488
489 fragment
490 HexadecimalEscapeSequence
491 : '\\x' HexadecimalDigit+
492
493
494 StringLiteral
495 : EncodingPrefix? '"' SCharSequence? '"'
496
497
498 fragment
499 EncodingPrefix
500 : 'u8'
501 | 'u'
502 | 'U'
503 | 'L'
504 ;
505
506 fragment
507 SCharSequence
508 : SChar+
509 ;
510
511 fragment
512 SChar
513 : ~["\\\r\n]
     EscapeSequence
514
     | '\\n' // Added line
| '\\r\n' // Added line
515
516
517
518
519 ComplexDefine
520 : '#' Whitespace? 'define' \sim[#\r\n]*
521 -> skip
522 ;
523
524 IncludeDirective
525 : '#' Whitespace? 'include' Whitespace? ('"' ~[\r\n]* '"' | '<' ~[\r\n]* '>' ) Whitespace? Newline
526
         -> skip
527 ;
528
529 AsmBlock
530 : 'asm' ~'{'* '{' ~'}'* '}'
531 -> skip
532
533
534 // ignore the lines generated by c preprocessor
535 // sample line : '#line 1 "/home/dm/files/dk1.h" 1'
536 LineAfterPreprocessing
    : '#line' Whitespace* \sim [\r \n]*
537
538
           -> skip
     ;
539
540
542 : '#' Whitespace? DecimalConstant Whitespace? StringLiteral \sim [\rn ]*
543
        -> skip
544
545
```